Prediction Probabiliste de la Fin d'Alerte Foudre

Processus de Hawkes, LightGBM & Quantile Regression

Data Battle 2026 – Meteorage

ZEROUALI Mohammed Amine & BOUBEKRI Saad

Equipe L2ay2ay

Mars 2026

Plan

1. Probleme et donnees
2. Pretraitement
3. Modele de Hawkes
4. LightGBM Quantile
5. Resultats
6. Responsabilite et impact

Probleme, donnees et objectif

Contexte

- Activites au sol suspendues des qu'un impact survient dans **20 km** d'un aeroport
- Regle actuelle : **30 min fixes** apres le dernier impact, quelle que soit la dynamique de l'orage
- **Chaque minute compte** – chargement, maintenance, embarquement

Objectif

Calculer a chaque instant τ_n le delai minimal u^* tel que : $\mathrm{P}\left(T > \tau_n + u^* \mid \mathcal{H}_n\right) < \varepsilon$
Gain $= 30 - u^*$ min. Contrainte jury : risque $R < 2\%$.

Donnees Meteorage (10 ans)

- 230 000 impacts de foudre
- 6 aeroports europeens
- Localisation + horodatage millimetre
- Zone alerte : 20 km | Zone etendue : 50 km

Notre approche hybride

Hawkes (MLE)	**LightGBM**
Modele generatif	Modele supervisé
Interpretable	Non-linearites
$\lambda^*(\tau_n)$ en feature	13 quantiles
Hybride : $\lambda^*(\tau_n) \in f_n$	

Pretraitement – la deduplication, une etape critique

Probleme : multi-detections capteurs

Le meme eclair physique est detecte simultanement par plusieurs capteurs $\Rightarrow$ doublons qui faussent le MLE.

Impact quantitatif sur $\hat{\alpha}$ (Ajaccio)

Seuil dedup	$\hat{\alpha}$	Physique ?
Aucun	254.1 imp/min	Non
10 sec	**0.212 imp/min**	**Oui**
1 min	0.049 imp/min	Non

Pipeline de pretraitement (5 etapes)

1. Parsing UTC $\rightarrow$ minutes Unix
2. Filtrage dist $\leq$ 20 km (alerte) et $\leq$ 50 km (features spatiales)
3. **Deduplication a 10 secondes** par aeroport
4. Segmentation par silence de **30 min**
5. Timestamps relatifs *et* absolus en parallele

Resultat

- 2 113 alertes d'entrainement
- 92 377 points de features
- 412 alertes de test couvertes

Pourquoi un processus de Hawkes ?

Observation physique

- Les impacts de foudre **ne sont pas independants**
- Un impact augmente la probabilite d'impacts futurs (*orage actif*)
- L'effet **decroit avec le temps** – orage qui s'eteint

Modele naturel : auto-excitation

$$\lambda^*(t) = \underbrace{\mu}_{\text{fond}} + \underbrace{\alpha \sum_{\tau_i < t} e^{-\beta(t-\tau_i)}}_{\text{excitation passee}}$$

- $\lambda^*(t)$ eleve $\Rightarrow$ orage actif
- $\lambda^*(t)$ faible $\Rightarrow$ orage en extinction

De λ^* a u^*

La probabilite d'aucun nouvel impact sur $[\tau_n, \tau_n + u]$:

$$P(T > \tau_n + u \mid \mathcal{H}_n) = \exp\left(-\int_{\tau_n}^{\tau_n+u} \lambda^*(s)\,\mathrm{d}s\right)$$

On cherche :

$$u^* = \inf\left\{u \in [0, 30] \;\middle|\; P(T > \tau_n + u \mid \mathcal{H}_n) < \varepsilon\right\}$$

Role cle pour LightGBM

$\lambda^*(\tau_n)$ est la **2e feature la plus importante** du modele LightGBM – lien direct entre physique et prediction.

Parametres Hawkes par aeroport et limites du modele

Parametres MLE (methode d'Ogata)

	$\hat{\mu}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha}/\hat{\beta}$
Ajaccio	0.056	0.212	0.241	0.880
Bastia	0.056	0.215	0.237	0.904
Biarritz	0.054	0.231	0.253	0.914
Nantes	0.057	0.231	0.256	0.903
Pise	0.056	0.204	0.229	0.892

Ratio $\hat{\alpha}/\hat{\beta} < 1$: stationnarite garantie.
Variations faibles entre aeroports : dynamique universelle.

Limite identifiee : μ constant

Test KS rejete ($p < 0.001$, KS ≈ 0.28–0.38).

Cause : $\mu =$ const ne capte pas le cycle de vie fini de l'orage. Le modele simule des alertes trop longues (≈ 160 min vs 60–140 min observees).

Ce que Hawkes apporte malgre tout

$\lambda^*(\tau_n)$ reste une **feature hybride cle** :

valeur elevee $\Rightarrow$ orage actif,
valeur faible $\Rightarrow$ orage qui se calme.

$\Rightarrow$ Capturee et exploitee par LightGBM.

LightGBM – Quantile regression et courbe de survie

Approche

Cible : $y = \tau_{n+1} - \tau_n \in (0, 30]$ min

13 modeles (pinball loss) pour $q \in \{5\%, \ldots, 95\%\}$

$\Rightarrow$ CDF empirique $\hat{F}_{Y|f_n}$

$\Rightarrow$ courbe de survie $\hat{S}(u) = 1 - \hat{F}(u)$

$\Rightarrow$ $u^* = \inf\{u \mid \hat{S}(u) < \varepsilon\}$

Vecteur $f_n \in \mathbb{R}^{12}$

Top features (gain LightGBM) :

1. `ia_mean5` – moyenne 5 dernieres inter-arrivees
2. `lambda_hawkes` – intensite Hawkes $\lambda^*(\tau_n)$
3. `ia_mean3` – fenetre courte de ralentissement
4. `amp_last`, `prop_cloud` – marques meteo

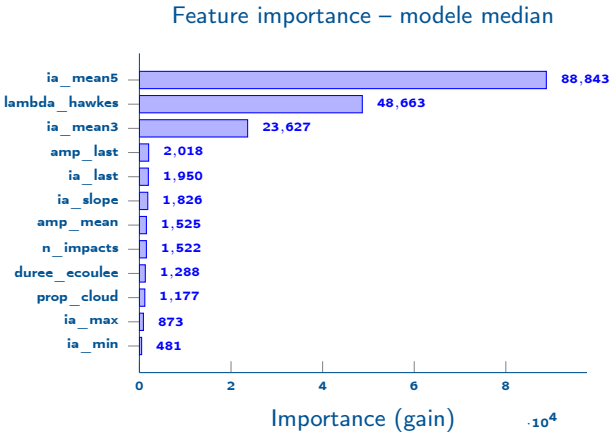

Gain vs Risque – courbe de Pareto

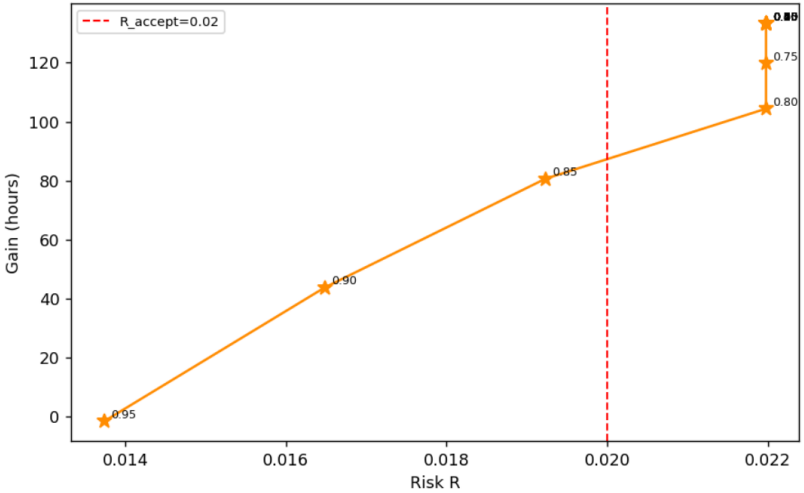

La courbe doit etre lue du **coin superieur gauche** (fort gain, faible risque). Le seuil $\theta^* = 0.85$ est le meilleur point respectant $R < 2\%$.

Resultats finaux – evaluation jury

Resultat cle ($\theta^* = 0.85$)

80 heures gagnees

Risque $R = 1.82\% < 2\%$ ✓

Detail par aeroport

Aeroport	Alertes	Gain (h)	Manques
Ajaccio	96	25.5	2
Bastia	141	20.3	5
Biarritz	118	7.8	0
Nantes	45	5.7	0
Pise	146	21.3	0
Total	**546**	**80.6**	**7**

Chiffres cles du pipeline

Donnees d'entrainement	92 377 exemples
Modeles entraines	13 quantiles
Alertes test couvertes	412 / 612
Predictions generees	323 820 lignes
Seuil optimal θ^*	0.85
Risque R	1.82%
Gain total	80 heures
Temps entrainement	$<$ 5 min CPU

Calibration des quantiles

Couverture reelle $\approx$ quantile theorique :
ex. $q = 0.80 \rightarrow 79.9\%$ observes.
$\Rightarrow$ Le modele est **bien calibre**.

Sobriete numerique et impact metier

Green coding

- **100% local** : aucun GPU, aucun cloud
- Entrainement LightGBM (92 000 ex., 13 modeles) : $<$ **5 min CPU**
- Inference vectorisee : 37 000 predictions en $<$ **30 s**
- Empreinte memoire : $<$ 500 Mo RAM

Comparaison energetique

Approche	Cout approx.
LLM meteo (GPU cloud)	~10–50 kWh
Transformer sequence	~1–5 kWh
Notre pipeline (CPU)	$<$ **0.05 kWh**

Impact operationnel

- **80 heures** gagnees sur 412 alertes test
- Reprise plus rapide : chargement, maintenance, embarquement
- Risque residuel ε explicite – outil de decision pour les responsables securite

Extensions futures

- **Hawkes marque** : $\alpha(d_i)$ integrant dist/amp
- **Hawkes non stationnaire** : $\mu(t)$ pour le cycle de vie de l'orage
- **API FastAPI** : flux Meteorage en temps reel
- **Quantile conforme** pour garanties exactes de couverture

Merci pour votre attention !

Questions ?

Code source disponible sur GitHub – equipe L2ay2ay