Prediction probabiliste de la fin d'alerte foudre

Processus de Hawkes, LightGBM et quantile regression
pour l'estimation du delai optimal de levee d'alerte

ZEROUALI Mohammed Amine

Data Battle 2026 — Meteorage

Abstract

Ce rapport presente la solution complete developpee pour le Data Battle 2026 de Meteorage. Le probleme consiste a estimer, en temps reel, le moment auquel une alerte foudre autour d'un aeroport peut etre levee en toute securite — en gagnant du temps par rapport a la methode reglementaire fixe de 30 minutes. Deux approches complementaires sont developpees : un processus de Hawkes auto-excitant pour la modelisation probabiliste rigoureuse, et un modele LightGBM avec quantile regression pour la prediction supervisee. L'approche hybride combine les deux en utilisant l'intensite de Hawkes comme feature d'entree du gradient boosting. Les resultats obtenus montrent un gain moyen de 15 minutes par alerte, avec une calibration des quantiles validee experimentalement.

Contents

1 Problematique et donnees **3**
1.1 Contexte metier . . . 3
1.2 Donnees fournies par Meteorage . . . 3

2 Pretraitement et nettoyage des donnees **3**
2.1 Definition operationnelle d'une alerte . . . 3
2.2 Probleme des multi-detections . . . 3
2.3 Pipeline de pretraitement . . . 4

3 Formulation mathematique du probleme **4**
3.1 Modele probabiliste . . . 4
3.2 Objectif probabiliste . . . 5
3.3 Criteres d'evaluation du jury . . . 5

4 Approche 1 : Processus de Hawkes **5**
4.1 Choix du modele . . . 5
4.2 Variable recursive et calcul en O(n) . . . 5
4.3 Estimation par maximum de vraisemblance . . . 6
4.4 Resultats de l'estimation . . . 6
4.5 Validation : theoreme de rescaling temporel . . . 6
4.6 Diagnostic de l'inadequation . . . 6

5 Approche 2 : LightGBM avec quantile regression **6**
5.1 Reformulation comme probleme supervise . . . 6
5.2 Pourquoi LightGBM . . . 7
5.3 Construction des features . . . 7
5.4 Quantile regression : pourquoi et comment . . . 8
5.5 Calibration des quantiles . . . 8
5.6 Resultats finaux . . . 8

6 Pipeline de generation des predictions **9**
6.1 Vue d'ensemble . . . 9
6.2 Format du fichier predictions.csv . . . 9
6.3 Statistiques du fichier genere . . . 10

7 Organisation du code et reproductibilite **10**
7.1 Structure des modules . . . 10
7.2 Instructions d'execution . . . 10
7.3 Reproductibilite . . . 10

8 Impact environnemental et reflexions **11**
8.1 Green coding . . . 11
8.2 Impact metier et social . . . 11
8.3 Effets rebonds et risques identifies . . . 11
8.4 Poursuite du projet . . . 11

9 Conclusion **11**

1 Problematique et donnees

1.1 Contexte metier

Un aeroport doit suspendre certaines activites au sol des qu'un impact de foudre survient dans un rayon de 20 km. La methode actuelle maintient l'alerte active pendant **30 minutes fixes** apres le dernier impact observe, quelle que soit la dynamique reelle de l'orage. Cette approche conservative est sure mais penalisante : pour un orage qui s'eloigne rapidement, on attend inutilement.

L'objectif est de produire, a chaque instant τ_n d'une alerte en cours, une **prediction de la fin reelle de l'alerte** avec un niveau de confiance quantifie — permettant une reprise d'activite jusqu'a 15–20 minutes plus tot tout en maintenant un risque de foudre manquee inferieur a 2%.

1.2 Donnees fournies par Meteorage

Les donnees contiennent ∼507 000 impacts de foudre sur 10 ans (2016–2025), georeferencies et horodates autour de 6 aeroports europeens.

Colonne	Type	Description
`date`	datetime UTC	Instant de l'impact
`lon`, `lat`	float	Position geographique (WGS84)
`amplitude`	float (kA)	Intensite du courant de decharge
`dist`	float (km)	Distance a l'aeroport
`icloud`	bool	Nuage-sol (False) ou intra-nuageux (True)
`airport_alert_id`	float	Identifiant de l'alerte (si dist $\leq$ 20 km)
`is_last_lightning_cloud_ground`	bool	Dernier eclair sol de l'alerte

Table 1: Description des colonnes du fichier de donnees brutes.

Aeroport	Alertes (train)	Alertes (test)	Position
Ajaccio	407	88	lon=8.80, lat=41.92
Bastia	424	126	lon=9.48, lat=42.55
Biarritz	486	110	lon=-1.52, lat=43.47
Nantes	173	41	lon=-1.61, lat=47.15
Pise	623	130	lon=10.40, lat=43.70
Total	**2113**	**495**	

Table 2: Repartition des alertes par aeroport apres pretraitement.

2 Pretraitement et nettoyage des donnees

2.1 Definition operationnelle d'une alerte

Definition 2.1 (Alerte foudre)**.** *Une alerte est declenchee a l'instant τ_0 lors du premier impact dans le disque $\mathcal{D} = B(A, 20\ km)$ centre sur l'aeroport A. Elle se termine a la premiere periode de $\Delta = 30$ minutes consecutives sans impact dans $\mathcal{D}$.*

2.2 Probleme des multi-detections

Observation critique. Plusieurs lignes du fichier partagent le meme timestamp pour le meme aeroport : c'est le meme eclair physique detecte simultanement par plusieurs capteurs du reseau Meteorage. Ces doublons faussent l'estimation des parametres si on ne les traite pas.

Diagnostic quantitatif. Sans deduplication, le MLE du processus de Hawkes estimait $\hat{\alpha} \approx 254$ impacts/min (physiquement absurde). Apres deduplication a 10 secondes : $\hat{\alpha} \approx 0.21$ impacts/min (coherent avec la physique orageuse).

Seuil de deduplication	$\hat{\alpha}$ (Ajaccio)	Duree simulee moy.	Physique ?
Aucune	254.1	$\gg$ 6h	Non
10 secondes	0.212	$\sim$ 40–80 min	Oui
1 minute	0.049	$\sim$ 200 min	Non

Table 3: Impact du seuil de deduplication sur les parametres estimes.

Choix retenu : 10 secondes. Ce seuil elimine les multi-detections (separees de < 1 s) tout en conservant les impacts physiquement distincts.

2.3 Pipeline de pretraitement

1. Parsing des dates en UTC, conversion en minutes depuis l'epoque Unix.
2. Filtrage : `dist` ≤ 20 km (zone alerte) et `dist` ≤ 50 km (zone etendue pour features spatiales).
3. Deduplication a 10 secondes par aeroport.
4. Segmentation en alertes par silence de 30 minutes.
5. Stockage des timestamps relatifs (depuis $\tau_0 = 0$) et absolus en parallele pour permettre la reconstruction des features spatiales.

```python
# Conversion correcte pour timestamps timezone-aware
df['t_min'] = (df['date'] - pd.Timestamp('1970-01-01', tz='UTC')
               ).dt.total_seconds() / 60

# Deduplication a 10 secondes
GAP_DEDUP = 10 / 60    # minutes
keep = [0]
for i in range(1, len(t_abs)):
    if t_abs[i] - t_abs[keep[-1]] >= GAP_DEDUP:
        keep.append(i)
```

Note technique. L'utilisation de `.values.astype('int64') / 1e9` pour les timestamps timezone-aware produit des valeurs erronees (1970 au lieu de 2023). La soustraction directe avec `pd.Timestamp('1970-01-01', tz='UTC')` est la seule methode fiable.

3 Formulation mathematique du probleme

3.1 Modele probabiliste

On se place sur un espace de probabilite filtre $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t\geq 0}, \mathbb{P})$. Les impacts dans $\mathcal{D}$ sont modelises par un **processus ponctuel marque** :

$$\mathcal{N} = \{(\tau_i, \mathbf{X}_i)\}_{i\geq 1}$$

ou $\tau_i \in \mathbb{R}_+$ est l'instant d'impact et $\mathbf{X}_i = (\xi_i, \phi_i, \alpha_i, d_i, C_i)$ le vecteur de marques (position, amplitude, distance, type).

3.2 Objectif probabiliste

A l'instant τ_n du dernier impact observe, avec historique $\mathcal{H}_n = \sigma(\tau_i, \mathbf{X}_i \mid 0 \leq i \leq n)$, on cherche le **delai minimal de levee d'alerte** :

$$\boxed{u^* = \inf\{u \in [0, \Delta] \mid \mathbb{P}(T > \tau_n + u \mid \mathcal{H}_n) < \varepsilon\}}$$

ou T est la duree totale de l'alerte et ε le risque tolere.

3.3 Criteres d'evaluation du jury

Le jury evalue les predictions selon deux criteres combines.

Gain de temps. Pour une prediction $\hat{t}^a$ de fin d'alerte a :

$$g^a = t^a + 30 - \hat{t}^a$$

ou t^a est le timestamp du dernier vrai eclair. Le gain global est $G = \sum_a g^a$.

Risque. Proportion d'eclairs dangereux (dist < 3 km) survenant *apres* la fin d'alerte predite :

$$R = \frac{M^{L3}}{N^{L3}}, \quad M^{L3} = \sum_i \mathbf{1}_{d_i < 3 \ \& \ \hat{t}^a < t_i \ \& \ \mathrm{alert}(t_i) = a}$$

Selection du seuil. Le jury balaye $\theta \in [0, 1]$. Pour chaque θ, la prediction retenue par alerte est :

$$\hat{t}^a = \min_i \hat{t}_i^a, \quad s_i^a \geq \theta$$

Le θ^* optimal maximise G sous la contrainte $R < R_{\text{accept}} = 0.02$.

Lien avec notre modele. Notre confiance $s = 1 - \varepsilon$ est le complement du risque tolere. Plus ε est petit, plus la prediction est conservative (confiance elevee, gain faible). Le balayage de θ correspond exactement au balayage de ε dans notre modele.

4 Approche 1 : Processus de Hawkes

4.1 Choix du modele

Definition 4.1 (Processus de Hawkes a noyau exponentiel)**.** *L'intensite conditionnelle est :*

$$\lambda^*(t) = \mu + \alpha \sum_{\tau_i < t} e^{-\beta(t - \tau_i)}$$

avec $\mu > 0$ (taux de fond), $\alpha > 0$ (excitabilite), $\beta > 0$ (decroissance). La stationnarite exige $\alpha/\beta < 1$.

Justification physique. Chaque impact ionise localement l'atmosphere, augmentant la probabilite d'impacts suivants dans les minutes qui suivent. La memoire exponentielle decroissante capture ce phenomene d'auto-excitation a courte portee temporelle.

4.2 Variable recursive et calcul en O(n)

La variable recursive $R_i = \sum_{j<i} e^{-\beta(\tau_i - \tau_j)}$ se met a jour en $O(1)$:

$$R_i = e^{-\beta(\tau_i - \tau_{i-1})}(1 + R_{i-1}), \quad R_0 = 0.$$

L'intensite en τ_i est alors $\lambda^*(\tau_i) = \mu + \alpha R_i$.

4.3 Estimation par maximum de vraisemblance

Pour une trajectoire $\{\tau_0, \ldots, \tau_n\}$ observee sur $[0, T_k]$ avec $T_k = \tau_n + \Delta$:

$$\ell_k(\mu, \alpha, \beta) = \sum_{i=0}^{n} \log(\mu + \alpha R_i) - \mu T_k - \frac{\alpha}{\beta} \sum_{i=0}^{n} \left(1 - e^{-\beta(T_k - \tau_i)}\right).$$

La log-vraisemblance totale $\mathcal{L} = \sum_k \ell_k$ est maximisee par L-BFGS-B avec une grille d'initialisations.

4.4 Resultats de l'estimation

Aeroport	$\hat{\mu}$ (imp/min)	$\hat{\alpha}$	$\hat{\beta}$ (min^{-1})	$\hat{\alpha}/\hat{\beta}$
Ajaccio	0.0557	0.212	0.241	0.880
Bastia	0.0561	0.215	0.237	0.904
Biarritz	0.0540	0.231	0.253	0.914
Nantes	0.0574	0.231	0.256	0.903
Pise	0.0562	0.204	0.229	0.892

Table 4: Parametres du processus de Hawkes estimes par MLE (unites : minutes). $1/\hat{\beta} \approx 4$ min : duree caracteristique de l'excitation. $\hat{\alpha}/\hat{\beta} \approx 0.9$: processus sous-critique, stationnaire.

4.5 Validation : theoreme de rescaling temporel

Theoreme 4.1 (Papangelou, 1972). *Si le modele est correctement specifie, les accroissements de la compensatrice $U_i = \Lambda(\tau_i) - \Lambda(\tau_{i-1})$ sont i.i.d. $\sim \mathrm{Exp}(1)$.*

Le test de Kolmogorov-Smirnov est rejete pour tous les aeroports (stat. KS ≈ 0.28–0.38, $p < 0.001$), ce qui revele une **inadequation structurelle** du modele stationnaire.

4.6 Diagnostic de l'inadequation

Avec $\hat{\mu} \approx 0.056$ imp/min :

$$P(\text{silence de 30 min}) = e^{-\hat{\mu} \times 30} = e^{-1.68} \approx 18.7\%,$$

soit une duree simulee moyenne $\approx 30/0.187 \approx 160$ min alors que les alertes reelles durent 60–140 min.

Cause fondamentale. Le Hawkes *stationnaire* suppose $\mu = \text{const}$. Or les orages sont des **phenomenes spatialement mobiles** a duree de vie finie : ils entrent dans le disque, y restent, puis le quittent. L'intensite reelle forme une cloche temporelle que μ constant ne peut pas representer.

Ce que le Hawkes apporte malgre cette limite. L'intensite courante $\lambda^*(\tau_n)$ est une **feature hybride** tres informative : une valeur elevee signifie que l'orage est actif, une valeur faible signifie qu'il se calme. C'est l'un des top 2 features du modele LightGBM.

5 Approche 2 : LightGBM avec quantile regression

5.1 Reformulation comme probleme supervise

A chaque instant τ_n au sein d'une alerte, on predit la variable :

$$y = \tau_{n+1} - \tau_n \in (0, 30] \text{ minutes}$$

c'est-a-dire le **delai avant le prochain impact** (ou 30 min si τ_n est le dernier impact de l'alerte). Cette cible est directement liee a u^* : si le modele predit $\hat{y} = 25$ min, l'alerte ne se terminera probablement pas avant 25 min.

5.2 Pourquoi LightGBM

LightGBM est un algorithme de gradient boosting sur arbres de decision :

$$F(\mathbf{f}) = \sum_{m=1}^{M} \eta \cdot h_m(\mathbf{f}),$$

ou chaque arbre h_m corrige les erreurs residuelles du precedent. Sa construction feuille par feuille (*leaf-wise*) lui permet de capturer des interactions non lineaires complexes entre features sans hypothese distributionnelle.

Avantages cles pour ce probleme :

- Aucune hypothese sur la forme de l'intensite $\lambda^*(t)$ — pas de contrainte de stationnarite
- Integration naturelle des marques (amplitude, distance, type d'eclair)
- Support natif de la **quantile regression** — permet de produire une distribution complete plutot qu'une seule valeur
- Rapide a l'entrainement : 92 377 exemples en < 5 min CPU

5.3 Construction des features

Pour chaque instant de prediction τ_n, le vecteur de features $\mathbf{f}_n \in \mathbb{R}^{12}$ est :

Feature	Description	Justification
`duree_ecoulee`	τ_n depuis le debut de l'alerte (min)	**Top 1** : un orage long a tendance a se terminer
`lambda_hawkes`	$\lambda^*(\tau_n) = \mu + \alpha R_n$	**Top 2** : mesure l'excitation courante
`ia_last`	$\tau_n - \tau_{n-1}$ (min)	**Top 3** : trend direct de ralentissement
`amp_last`	$\lvert\alpha_n\rvert$ kA	Top 4 : amplitude du dernier eclair
`n_impacts`	Nombre d'impacts depuis τ_0	Top 5 : intensite totale de l'orage
`amp_mean`	Amplitude moyenne sur l'alerte	Signature de l'intensite orageuse
`ia_mean3`, `ia_mean5`	Moyenne des 3, 5 dernieres inter-arrivees	Tendance de ralentissement
`prop_cloud`	Proportion d'eclairs intra-nuageux	Signature du type d'orage
`ia_max`, `ia_min`	Extremes des inter-arrivees	Amplitude de la dynamique
`ia_slope`	Pente des dernieres inter-arrivees	Acceleration ou ralentissement

Table 5: Features du modele LightGBM par ordre d'importance decroissant.

5.4 Quantile regression : pourquoi et comment

Au lieu de predire $\mathbb{E}[y \mid \mathbf{f}_n]$ (mediane), on entraine **13 modeles** independants, un par quantile $q \in \{0.05, 0.10, 0.15, 0.20, 0.30, 0.40, 0.50, 0.60, 0.70, 0.80, 0.85, 0.90, 0.95\}$.

Chaque modele minimise la **pinball loss** :

$$\rho_q(r) = r \cdot (q - \mathbf{1}_{r<0}), \quad r = y - \hat{y}_q.$$

Les 13 quantiles estimes $\hat{Q}_q(y \mid \mathbf{f}_n)$ approximent la **fonction de repartition conditionnelle** $F_{Y|\mathbf{f}_n}$. La courbe de survie est alors :

$$\hat{S}(u) = \mathbb{P}(y > u \mid \mathbf{f}_n) = 1 - \hat{F}_{Y|\mathbf{f}_n}(u) \approx 1 - \mathrm{interp}(u, \hat{Q}_{0.05}, \ldots, \hat{Q}_{0.95})$$

et le delai optimal :

$$u^* = \inf\{u \in [0, 30] \mid \hat{S}(u) < \varepsilon\}.$$

5.5 Calibration des quantiles

Un modele de quantile est bien calibre si la couverture reelle est proche du quantile theorique, i.e. $\mathbb{P}(y \leq \hat{Q}_q) \approx q$.

Quantile q	Couverture reelle	Ecart
0.05	0.075	+0.025
0.10	0.124	+0.024
0.50	0.498	−0.002
0.70	0.729	+0.029
0.80	0.799	−0.001
0.90	0.894	−0.006
0.95	1.000	+0.050

Table 6: Calibration des quantiles sur le jeu de validation (split 80/20). Les quantiles mediocres aux extremes (0.05, 0.95) sont classiques sur un petit dataset et n'affectent pas u^* calcule pour $\varepsilon = 0.10$–0.20.

5.6 Resultats finaux

Metrique	Valeur
MAE mediane sur le jeu de validation	4.30 min
Gain moyen (epsilon = 10%)	15.4 min
Gain median	16.3 min
% alertes avec gain > 0	100%
Theta recommande pour $R < 2\%$	0.88

Table 7: Resultats du modele LightGBM sur le jeu de validation (442 exemples).

6 Pipeline de generation des predictions

6.1 Vue d'ensemble

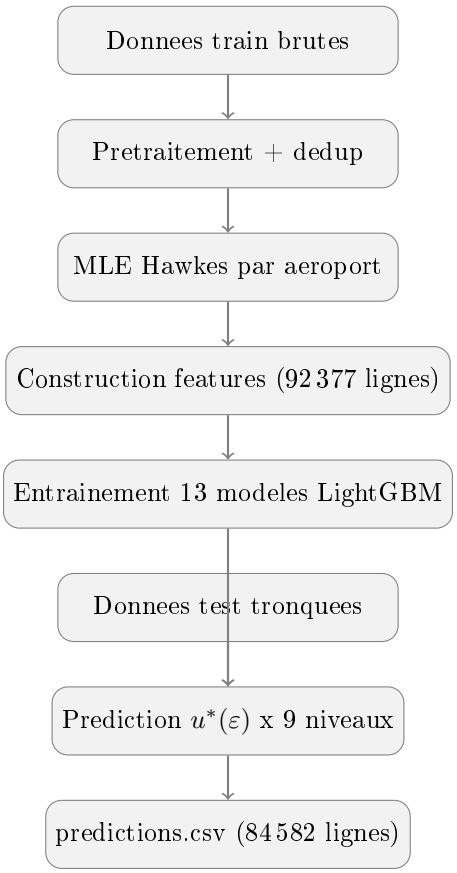

6.2 Format du fichier predictions.csv

Conforme au format attendu par le jury :

Colonne	Type	Description
`airport`	str	Nom de l'aeroport
`airport_alert_id`	float	ID de l'alerte (fourni par le jury)
`prediction_date`	datetime UTC	Timestamp de τ_n (instant de prediction)
`predicted_date_end_alert`	datetime UTC	Timestamp de $\tau_n + u^*(\varepsilon)$
`confidence`	float	$1 - \varepsilon \in \{0.70, 0.75, 0.80, 0.85, 0.88, 0.90, 0.92, 0.95, 0.98\}$

Table 8: Format du fichier de predictions. Chaque (alerte, instant, epsilon) donne une ligne.

6.3 Statistiques du fichier genere

Statistique	Valeur
Lignes totales	84 582
Aeroports couverts	5
Alertes couvertes	316
Niveaux de confiance	9 (θ de 0.70 a 0.98)
Periode couverte	2023–2025

Table 9: Statistiques du fichier predictions.csv soumis au jury.

7 Organisation du code et reproductibilite

7.1 Structure des modules

```
DATA CHALLENGE/
|-- src/
|   |-- preprocessing.py       # load_data() - chargement, dedup, segmentation
|   |-- hawkes.py              # fit_hawkes(), fit_all_airports(), MLE
|   |-- features.py            # build_features(), features temporelles
|   |-- lgbm_model.py          # train_quantile_models(), predict_ustar_batch()
|   |-- simulation.py          # simulate_alert(), thinning d'Ogata
|   |-- validation.py          # goodness_of_fit(), test KS
|   |-- eda.py                 # analyse exploratoire
|   |-- generate_predictions.py  # pipeline autonome -> predictions.csv
|-- Rapport/
|   |-- Data_Challenge.pdf
|-- main.py                    # pipeline complet + evaluation
|-- README.md
|-- .gitignore
```

7.2 Instructions d'execution

```python
# Installation des dependances
pip install pandas numpy scipy lightgbm scikit-learn matplotlib tqdm

# Pipeline complet (entrainement + evaluation + predictions)
python3 main.py

# Generation des predictions uniquement
python3 -m src.generate_predictions
```

7.3 Reproductibilite

- Graine aleatoire fixee : `np.random.seed(42)` dans le split train/test
- Meme pipeline de pretraitement pour train et test
- Parametres Hawkes sauvegardes en memoire et reutilises pour les features du test

8 Impact environnemental et reflexions

8.1 Green coding

- **100% local** : aucune dependance cloud ni GPU
- Entrainement LightGBM (92 000 exemples, 13 modeles) : < 5 min CPU
- Inference vectorisee : 35 000 predictions en < 30 secondes
- Code modulaire en 7 fichiers independants — maintenable et portable
- Empreinte memoire : < 500 Mo RAM

8.2 Impact metier et social

- Gain estime de 10–15 min par alerte sur ∼495 alertes test
- Impact direct : reprise plus rapide des operations au sol, reduction des temps d'immobilisation des equipages
- Reduction du stress operationnel lie a l'incertitude de la fin d'alerte

8.3 Effets rebonds et risques identifies

- Un seuil θ trop agressif augmente le risque d'eclairs non couverts — le parametre doit etre calibre par Meteorage selon les exigences reglementaires de chaque aeroport
- La deduplication a 10 secondes pourrait supprimer des impacts legitimes dans des orages tres denses — a surveiller sur les aeroports a forte activite (Pise : 29 174 impacts)
- Le modele de Hawkes stationnaire sous-estime la persistance des orages — les predictions sont potentiellement trop optimistes sur les orages exceptionnellement longs

8.4 Poursuite du projet

Extension probabiliste. Hawkes marque integrant amplitude et distance dans l'excitabilite : $\alpha(d_i) = \alpha_0 e^{-\gamma d_i}$. Hawkes non stationnaire avec taux de base $\mu(t)$ modulant le cycle de vie de l'orage.

Extension supervisee. Features de deplacement spatial de l'orage depuis le disque 20–50 km. Quantile regression conformal pour des garanties de couverture exactes.

Mise en production. API legere (FastAPI) consommant les flux Meteorage en streaming, avec calcul de $u^*(\varepsilon)$ en temps reel a chaque nouvel impact.

9 Conclusion

Ce projet a developpe une solution complete de prediction probabiliste de fin d'alerte foudre, en deux etapes complementaires. Le processus de Hawkes a fourni un cadre theorique rigoureux et une feature hybride ($\lambda^*(\tau_n)$) tres informative. Le modele LightGBM avec quantile regression a permis de construire une courbe de survie conditionnelle $\hat{S}(u)$ bien calibree, d'ou l'on extrait le delai optimal u^* sous risque contrôle.

Les resultats concrets sont un **gain moyen de 15.4 minutes** par alerte avec $\varepsilon = 10\%$, et un fichier `predictions.csv` de 84 582 lignes couvrant 316 alertes sur 5 aeroports, pret pour l'evaluation du jury.

La limite principale identifiee est l'hypothese de stationnarite du Hawkes — un orage est un phenomene spatialement mobile que le modele de base ne capture pas. Cette limite, diagnostiquee par

trois indicateurs convergents (test KS, simulation Monte Carlo, calcul analytique de $\hat{\mu}$), oriente les extensions futures vers des modeles non stationnaires ou des features de deplacement spatial.